

Proyecto final de redes neuronales

Análisis de sentimiento en reseñas

Integrantes:

Isabela Mendoza
Miguel Ángel Ortiz
Luis Ángel Nerio
César Montoya

Índice

1. Problema, datos y objetivo
2. Preprocesamiento y arquitecturas evaluadas
3. Validación, resultados y análisis
4. Conclusión, uso de IA y referencias

1. Problema, datos y objetivo

El proyecto aborda una tarea de NLP: clasificar automáticamente reseñas en inglés como positivas o negativas. El objetivo técnico fue comparar tres enfoques de complejidad creciente y seleccionar el modelo con mejor generalización en test. Se eligió **IMDB 50K** como dataset final por estar balanceado y por ser un benchmark de clasificación binaria de sentimiento.

Dataset usado

50,000 reseñas de películas con etiqueta binaria. El EDA del proyecto confirmó 25,000 positivas y 25,000 negativas, sin valores nulos en review/sentiment. La longitud media fue 231.2 palabras, mediana 173 y percentil 95 de 590 palabras.

Split	Cantidad	Proporción	Balance de clases	Uso
Train	35,020	70%	50% pos / 50% neg	Ajuste de pesos
Validation	7,480	15%	50% pos / 50% neg	Selección de hiperparámetros/modelo
Test	7,500	15%	50% pos / 50% neg	Evaluación final no usada para entrenar

La partición 70/15/15 es adecuada porque reserva suficientes datos para entrenar, mantiene un conjunto de validación para tomar decisiones sin tocar test y deja una prueba final independiente. Se usó estratificación, por eso cada split conserva el balance 50/50.

2. Preprocesamiento y arquitecturas evaluadas

Para MLP y LSTM se usó texto limpio: eliminación de etiquetas HTML, minúsculas, limpieza de signos/caracteres especiales y representación numérica.

En MLP se vectorizó con TF-IDF; en LSTM se usó tokenización secuencial.

Para Transformer se mantuvo texto bruto y se aplicó el tokenizer de distilbert-base-uncased con input_ids y attention_mask, porque el modelo pre entrenado espera la misma tokenización usada durante su pre entrenamiento.

Modelo	Entrada	Arquitectura	Loss / optimizador	Épocas / batch / hardware
MLP baseline	TF-IDF limitado a 500 features	Dense(32, ReLU) + Dropout(0.6) + Dense(1, sigmoid), 16,065 parámetros	Binary crossentropy / SGD lr=0.1	20 / 1024 / CPU
LSTM	Secuencias; vocab=20,000; max_len=200	Embedding(64) + SpatialDropout + LSTM(128) + Dense(32) + Dropout(0.3) + sigmoid	Binary crossentropy / Adam lr=0.001	10 / 128 / CPU
DistilBERT	Tokens WordPiece; max_len=256	DistilBERT + embedding [CLS] + Dropout(0.3) + Linear(768→2), 66,364,418 parámetros entrenables	CrossEntropyLoss / AdamW lr=2e-5	3 / 16 / GPU CUDA

El modelo final seleccionado fue DistilBERT, porque obtuvo el mejor F1 y accuracy en test. A diferencia de MLP, conserva contexto; y frente a LSTM aprovecha transfer learning, es decir, conocimiento lingüístico pre entrenado.

3. Validación, resultados y análisis

La validación se monitoreó con accuracy, F1, loss y, cuando aplicaba, AUC-ROC. En MLP y LSTM se usaron callbacks de checkpoint/early stopping o reducción de tasa de aprendizaje. En Transformer se guardó el mejor checkpoint según F1 de validación; el test solo se ejecutó al final.

Modelo	Train acc.	Val acc.	Test acc.	Test F1	AUC/Notas
MLP	0.5168	0.5408	0.5503	0.5772	AUC=0.5601; underfitting claro
LSTM	0.8267	0.7830	0.7845	0.7949	AUC=0.7940; generalización aceptable

DistilBERT	0.9706	0.9206	0.9153	0.9153	Mejor modelo; precisión=0.9153, recall=0.9153
------------	--------	--------	--------	--------	---

Cálculo de mejora: DistilBERT superó al LSTM en 13.08 puntos porcentuales de accuracy ($0.9153 - 0.7845 = 0.1308$) y al MLP en 36.50 puntos porcentuales ($0.9153 - 0.5503 = 0.3650$).




Figura 1. Curvas de entrenamiento del Transformer: loss y F1 por época.

Análisis de sobre/infraajuste

el MLP no aprendió patrones suficientes, lo que se observa en loss ≈ 0.693 y accuracy cercana al azar mientras que La LSTM mejoró sustancialmente, pero todavía pierde información por vocabulario limitado y tokens OOV.

Finalmente, DistilBERT mostró la mejor generalización; aunque existe una brecha train-val de 0.0500 y la loss de validación sube en la última época, el F1 de validación y el F1 de test permanecen altos y consistentes.

Análisis de errores

en test, DistilBERT obtuvo matriz $[[3398, 352], [283, 3467]]$, es decir, 635 errores de 7,500 muestras. Se equivocó un poco más clasificando reseñas negativas como positivas (352 FP) que positivas como negativas (283 FN). Los errores más probables aparecen en reseñas largas, ambiguas, con ironía, mezcla de elogios/críticas o señales sentimentales contradictorias. En LSTM, los errores fueron mayores: 998 FP y 618 FN.

4. Conclusión, uso de IA y referencias

Conclusión: la comparación confirma que la representación del lenguaje es decisiva. MLP sirve como línea base, LSTM captura secuencia y mejora el desempeño, pero DistilBERT es la mejor alternativa para este dataset porque combina contexto bidireccional, embeddings preentrenados y fine-tuning supervisado.

Uso de IA

se utilizó ChatGPT como apoyo para organizar la documentación, resumir métricas y redactar el análisis, además de apoyo técnico en la creación del código de los modelos. El equipo conservó la responsabilidad de validar, entender y sustentar el código, los resultados y las decisiones del proyecto.